

Analyse structurelle et lexicale

Ponctuation et détail

On observe une prépondérance de l'usage des astérisques (« * », 2868 occurrences) dans les textes générés par IA. Ceux-ci semblent principalement employés afin de créer une forme d'emphasis typographique, notamment parce que de nombreux sites et langages de balisage utilisent les astérisques pour mettre du texte en gras ou en italique.

Par ailleurs, les systèmes générés par IA ont tendance à privilégier l'utilisation de symboles en forme d'étoiles pour exprimer la notation (« rating ») des *reviews*, généralement accompagnés d'une valeur numérique entre parenthèses. À l'inverse, les textes humains ont un emploi presque systématique des formulations textuelles telles que « x out of 5 » afin d'exprimer la même quantification.

Le signe égal (« = ») apparaît également avec une très grande fréquence dans les textes générés par IA (2320 occurrences, pour être exact). Toutefois, son rôle semble davantage structurel dans les *reviews*, servant à organiser ou segmenter l'information. On observe un phénomène similaire pour les guillemets, nettement plus présents dans les textes produits par IA (IA : 1060 occurrences ; humains : 401 occurrences).

À l'inverse, certains signes de ponctuation sont davantage employés dans les textes rédigés par des humains. C'est notamment le cas du point-virgule (humains : 170 occurrences ; IA : 90 occurrences) ainsi que du point d'interrogation (humains : 173 occurrences ; IA : 55 occurrences). De plus, les parenthèses apparaissent plus fréquemment dans les productions humaines (environ 400 occurrences contre environ 180 dans les textes générés par IA).

En revanche, pour les signes de ponctuation les plus courants, tels que le point et la virgule, les écarts de fréquence demeurent très faibles. Nous en avons donc conclu que leur fréquence d'emploi était globalement similaire dans les deux corpus.

Lexical et structure

En ce qui concerne les choix lexicaux, ceux-ci dépendent fortement des ouvrages concernés, ce qui rend les *reviews* relativement peu unanimes sur ce point. Sans surprise, les mots les plus fréquents dans les deux corpus sont principalement des mots grammaticaux tels que *the*, *of*, *with*, *as*, *to* et *for*.

Cependant, certaines différences notables apparaissent entre les textes humains et ceux générés par IA. Le pronom de première personne *I* est ainsi largement plus présent dans les productions humaines, avec 1520 occurrences contre seulement environ 300 dans les textes générés par intelligence artificielle. Le mot *in* est également plus fréquemment employé par les rédacteurs humains. On remarque également une utilisation plus variée des connecteurs logiques dans le corpus généré par IA, avec l'emploi fréquent de termes tels que *overall* ou *however*. On observe également un emploi plus fréquent de mots tels que *beautiful* ou *love* dans le corpus humain. Toutefois, les termes à connotation émotionnelle ou empathique ne sont pas aussi présents que ce que nous aurions pu anticiper dans ce corpus.

On remarque par ailleurs une présence nettement **plus importante du possessif féminin *her*** dans les textes humains (environ 400 occurrences, contre seulement une centaine dans les textes générés par IA). Cette disparité ne se retrouve toutefois pas pour les autres déterminants possessifs.

Nous avons également remarqué que les textes générés par IA présentent **très peu de structures comparatives**. À l'inverse, les textes rédigés par des humains en contiennent plus d'une centaine à l'échelle de l'ensemble du corpus. Cette différence se manifeste notamment par l'absence presque totale du mot *than* dans les productions générées par IA, alors qu'il est fréquemment utilisé dans les textes humains pour introduire des comparaisons en combinaison avec des termes tels que *better* ou *rather*. Ces derniers sont également largement absents du corpus produit par IA.

L'analyse de la structure des textes s'avère relativement complexe. En effet, la méthode de collecte du corpus humain a considérablement modifié son organisation initiale, rendant les comparaisons plus difficiles. Il demeure néanmoins possible d'étudier les différentes structures présentes dans le corpus généré par IA.

Deux structures principales peuvent être observées. La première correspond à une **organisation claire et ordonnée**, composée de sections distinctes, souvent numérotées. Cette structure apparaît dans un certain nombre de reviews générées par intelligence artificielle. La seconde est **plus organique** et cherche davantage à imiter l'écriture humaine : les différents points y sont abordés successivement de manière cohérente, mais sans plan explicitement défini.

Malgré cette apparente spontanéité, les textes générés par IA conservent généralement une structure globale claire et maîtrisée. À l'inverse, les reviews rédigées par des humains présentent plus fréquemment une organisation décousue, avec des idées abordées dans le désordre ou des retours sur des points déjà évoqués.

Nous pensions également observer une différence concernant la longueur des reviews, hypothèse qui s'est effectivement vérifiée. Toutefois, certaines reviews du corpus humain se distinguaient également par leur longueur et leur niveau de structuration, parfois comparables à ceux des textes générés par IA.